Tedu.cn
达内教育

Linux 大数据

NSD HADOOP DAY01

内容

上午	09:00 ~ 09:30	什么是大数据
	09:30 ~ 10:20	大数据能做什么
	10:30 ~ 11:20	Hadoop历史起源
	11:30 ~ 12:00	Hadoop 组件介绍
下午	14:00 ~ 14:50	Hadoop安装配置
	15:00 ~ 15:50	
	16:10 ~ 17:00	Hadoop搭建练习
	17:10 ~ 18:00	总结和答疑

大数据

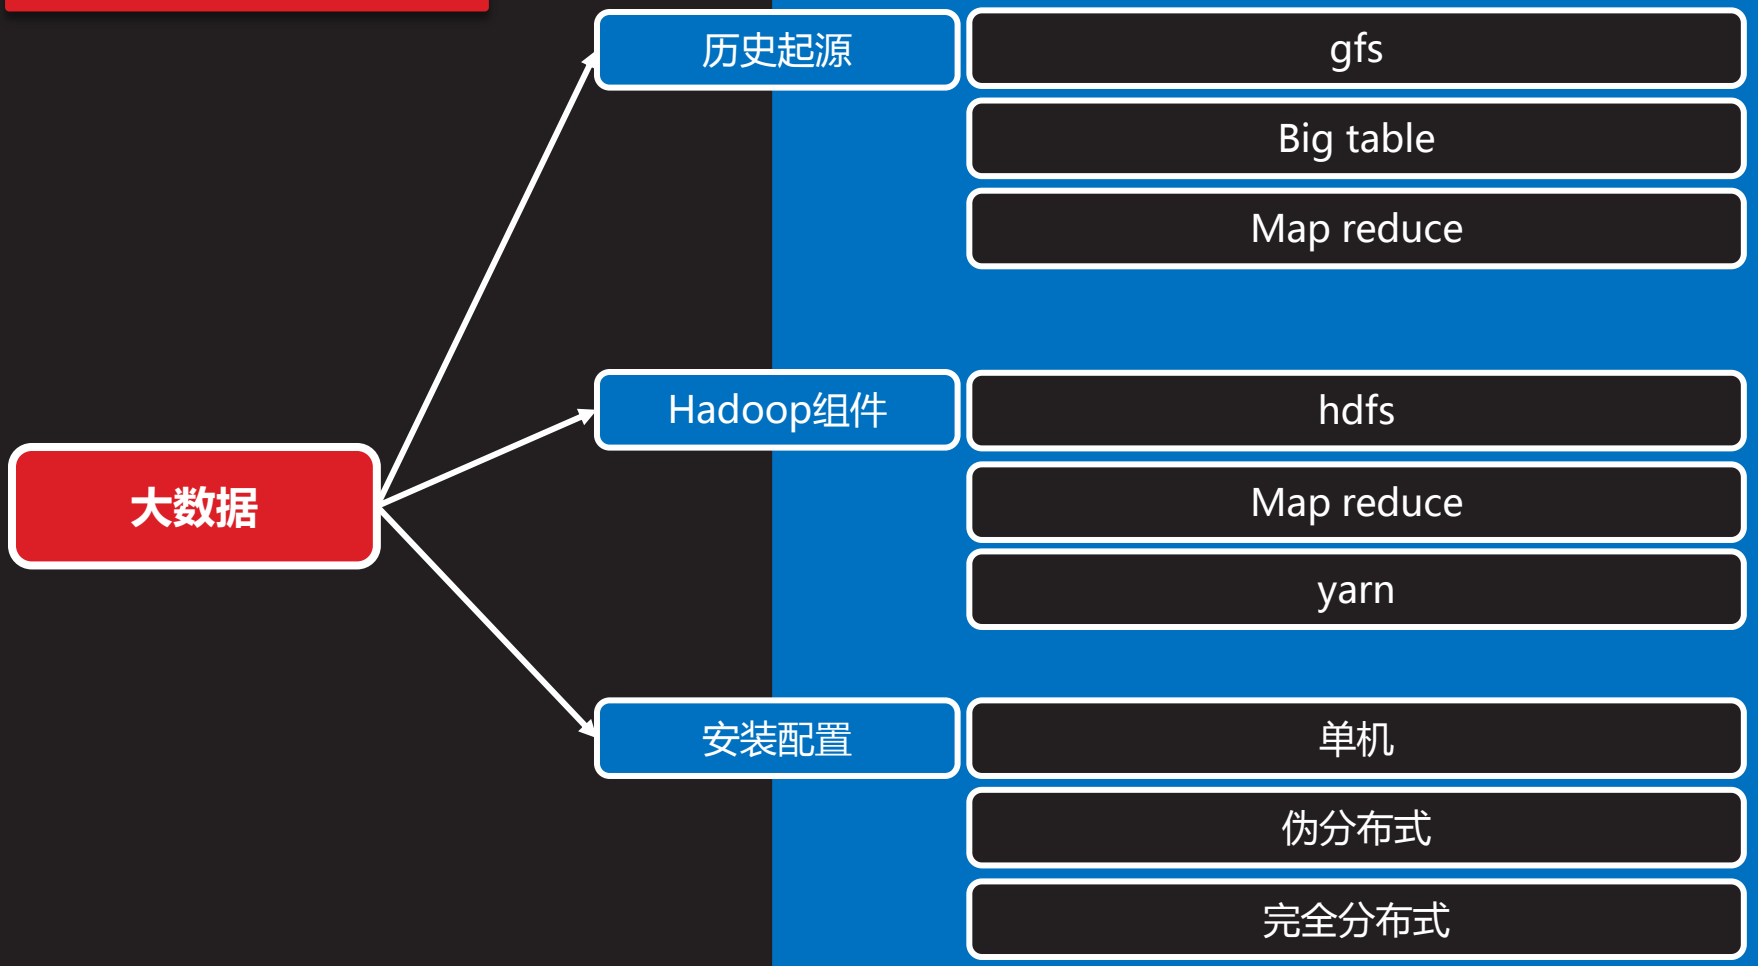
大数据
历史起源
gfs
Big table
Map reduce
Hadoop组件
hdfs
Map reduce
yarn
安装配置
单机
伪分布式
完全分布式

Tedu.cn
达内教育

大数据介绍

大数据是做什么的

- 大数据
  - 随着计算机技术的发展，互联网的普及，信息的积累已经到了一个非常庞大的地步，信息的增长也在不断的加快，随着互联网、物联网建设的加快，信息更是爆炸是增长，收集、检索、统计这些信息越发困难，必须使用新的技术来解决这些问题

知识讲解

什么是大数据

- 大数据的定义
  - 大数据由巨型数据集组成，这些数据集大小常超出人类在可接受时间下的收集、庋用、管理和处理能力。
- 大数据能做什么？
  - 把数据集合并后进行分析可得出许多额外的信息和数据关系性，可用来察觉商业趋势、判定研究质量、避免疾病扩散、打击犯罪或测定即时交通路况等；这样的用途正是大型数据集盛行的原因
  - ----摘自 维基百科

知识讲解

什么是大数据

- 大数据的定义
  - 大数据指无法在一定时间范围内用常规软件工具进行捕捉、管理和处理的数据集合，是需要新处理模式才能具有更强的决策力、洞察发现力和流程优化能力的海量、高增长率和多样化的信息资产。
- 大数据能做什么？
  - 企业组织利用相关数据和分析可以帮助它们降低成本、提高效率、开发新产品、做出更明智的业务决策等等。
  - ----摘自 百度百科

知识讲解

什么是大数据

- 大数据的定义
  - 大数据是指无法在一定时间内用常规软件工具对其内容进行抓取、管理和处理的数据集合。大数据技术，是指从各种各样类型的数据中，快速获得有价值信息的能力。适用于大数据的技术，包括大规模并行处理数据库，数据挖掘电网，分布式文件系统，分布式数据库，云计算平台，互联网，和可扩展的存储系统。
  - ----摘自 MBA智库

知识讲解

大数据的特性

知识讲解

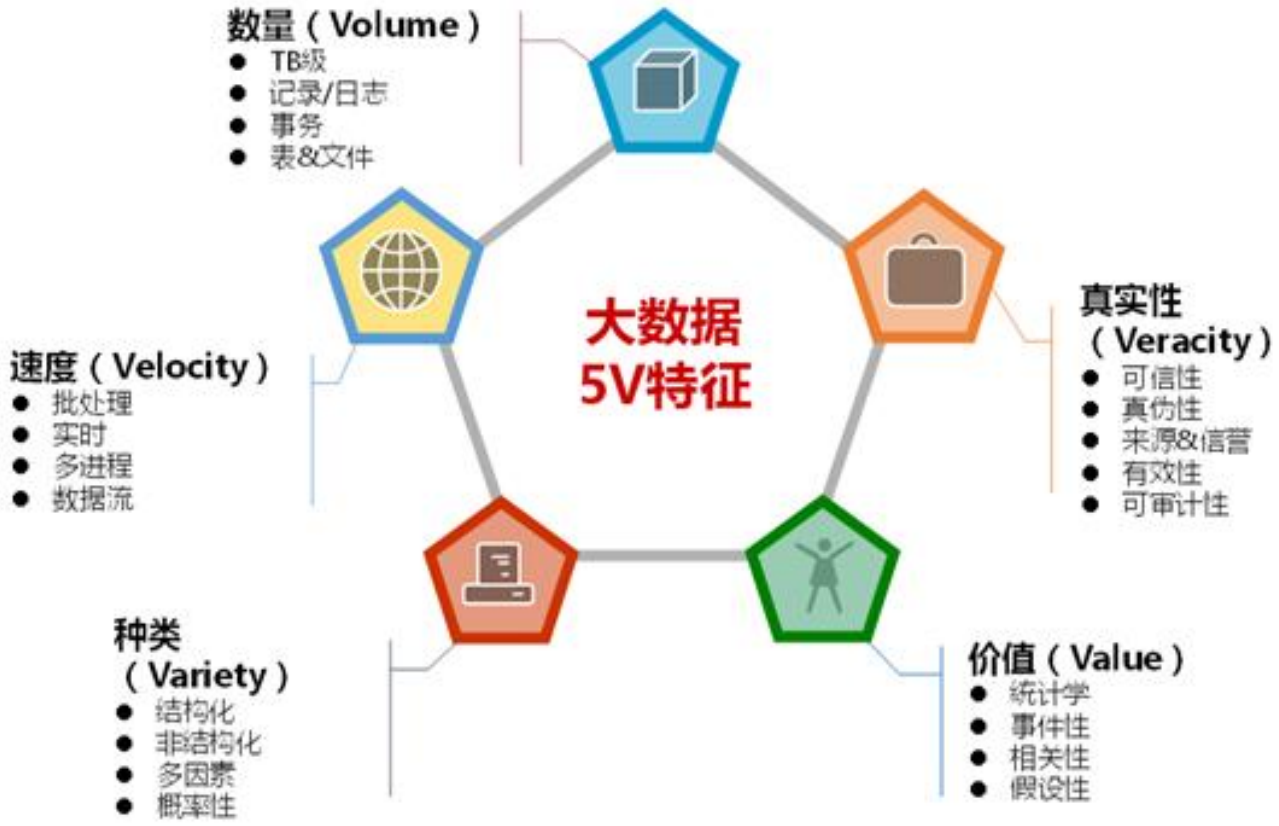

大数据特性

- 大数据的 5V 特性是什么？
  - (V)olume (大体量)

    即可从数百TB到数十数百PB、甚至EB的规模。
  - (V)ariety(多样性)

    即大数据包括各种格式和形态的数据。
  - (V)elocity(时效性)

    即很多大数据需要在一定的时间限度下得到及时处理。
  - (V)eracity(准确性)

    即处理的结果要保证一定的准确性。
  - (V)alue(大价值)

    即大数据包含很多深度的价值，大数据分析挖掘和利用将带来巨大的商业价值。

知识讲解

大数据与Hadoop

知识讲解

- Hadoop 是什么
  - Hadoop 是一种分析和处理海量数据的软件平台
  - Hadoop 是一款开源软件，使用 JAVA 开发
  - Hadoop 可以提供一个分布式基础架构

- Hadoop 特点
  - 高可靠性、高扩展性、高效性、高容错性、低成本

Hadoop 历史起源

Hadoop 起源

- 2003 年开始 google 陆续发表了几篇论文：
  - GFS， MapReduce， BigTable
  - GFS是一个可扩展的分布式文件系统，用于大型的、分布式的、对大量数据进行访问的应用。它运行于廉价的普通硬件上，提供容错功能。
  - Mapreduce 是针对分布式并行计算的一套编程模型
  - Mapreduce是由Map和reduce组成，Map是影射，把指令分发到多个worker上去，reduce是规约，把Map的worker计算出来的结果合并

知识讲解

Hadoop 起源

- 2003 年开始 google 陆续发表了几篇论文：
  - GFS， MapReduce， BigTable
  - BigTable 存储结构化数据。
  - BigTable 是建立在 GFS ，Scheduler ，Lock Service 和 MapReduce 之上的。
  - 每个 Table 都是一个多维的稀疏图

知识讲解

Hadoop 起源

- 这三大技术被称为 Google 的三驾马车。
- 虽然Google没有公布这三个产品的源码，但是他发布了这三个产品的详细设计论文。
- Yahoo 资助的 Hadoop 按照这三篇论文的开源Java实现，不过在性能上 Hadoop 比 Google 要差很多。
  - GFS - - -> HDFS
  - Mapreduce - - -> Mapreduce
  - Bigtable - - -> Hbase

知识讲解

Tedu.cn
达内教育

Hadoop 组件

Hadoop 核心组件

知识讲解

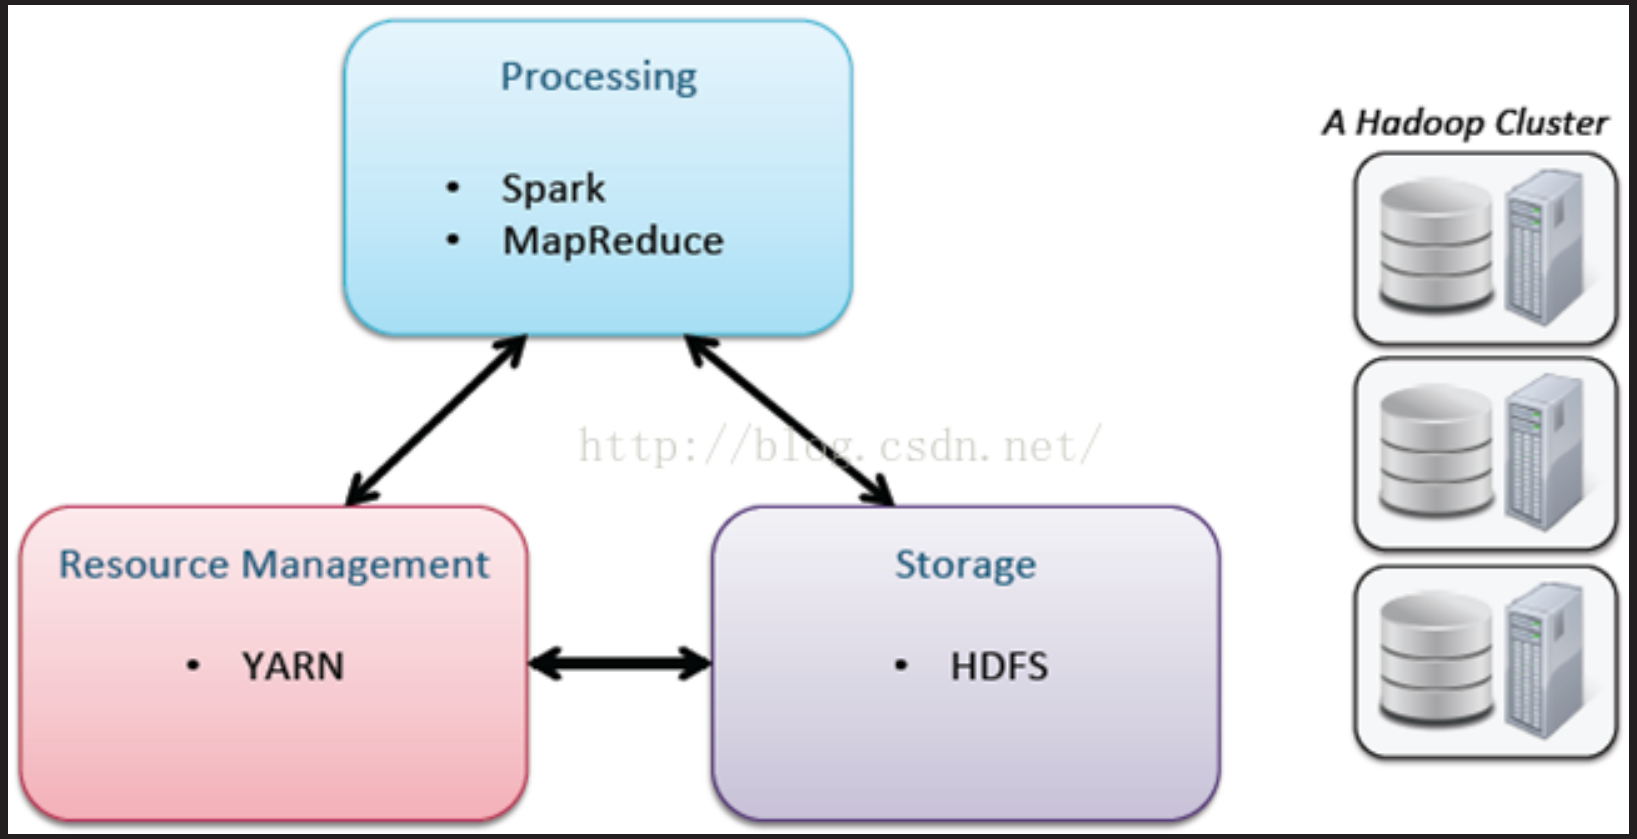

Hadoop 核心组件

- HDFS
  - 分布式文件系统
- MapReduce
  - 分布式计算框架
- Yarn
  - 集群资源管理系统

知识讲解

Hadoop 生态系统

知识讲解

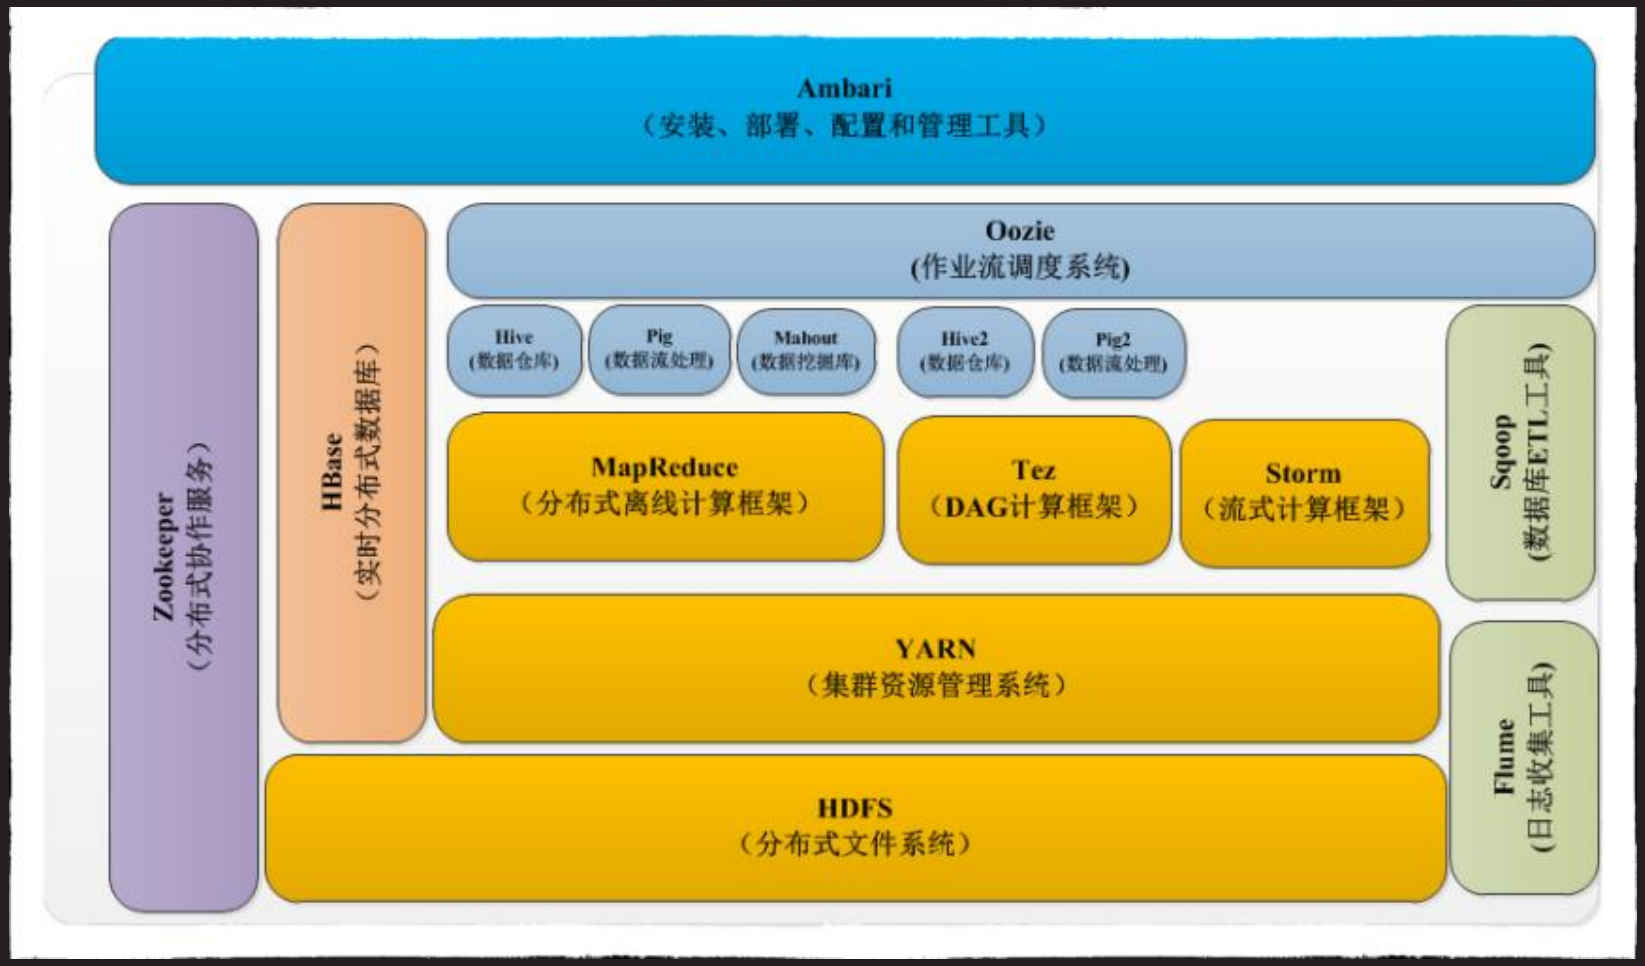

Hadoop 常用组件

- HDFS（Hadoop分布式文件系统）
- Mapreduce（分布式计算框架）
- Zookeeper（分布式协作服务）
- Hbase（分布式列存数据库）
- Hive（基于Hadoop的数据仓库）
- Sqoop（数据同步工具）
- Pig（基于Hadoop的数据流系统）
- Mahout（数据挖掘算法库）
- Flume（日志收集工具）

知识讲解

Tedu.cn
达内教育

Hadoop 核心组件

HDFS 结构

知识讲解

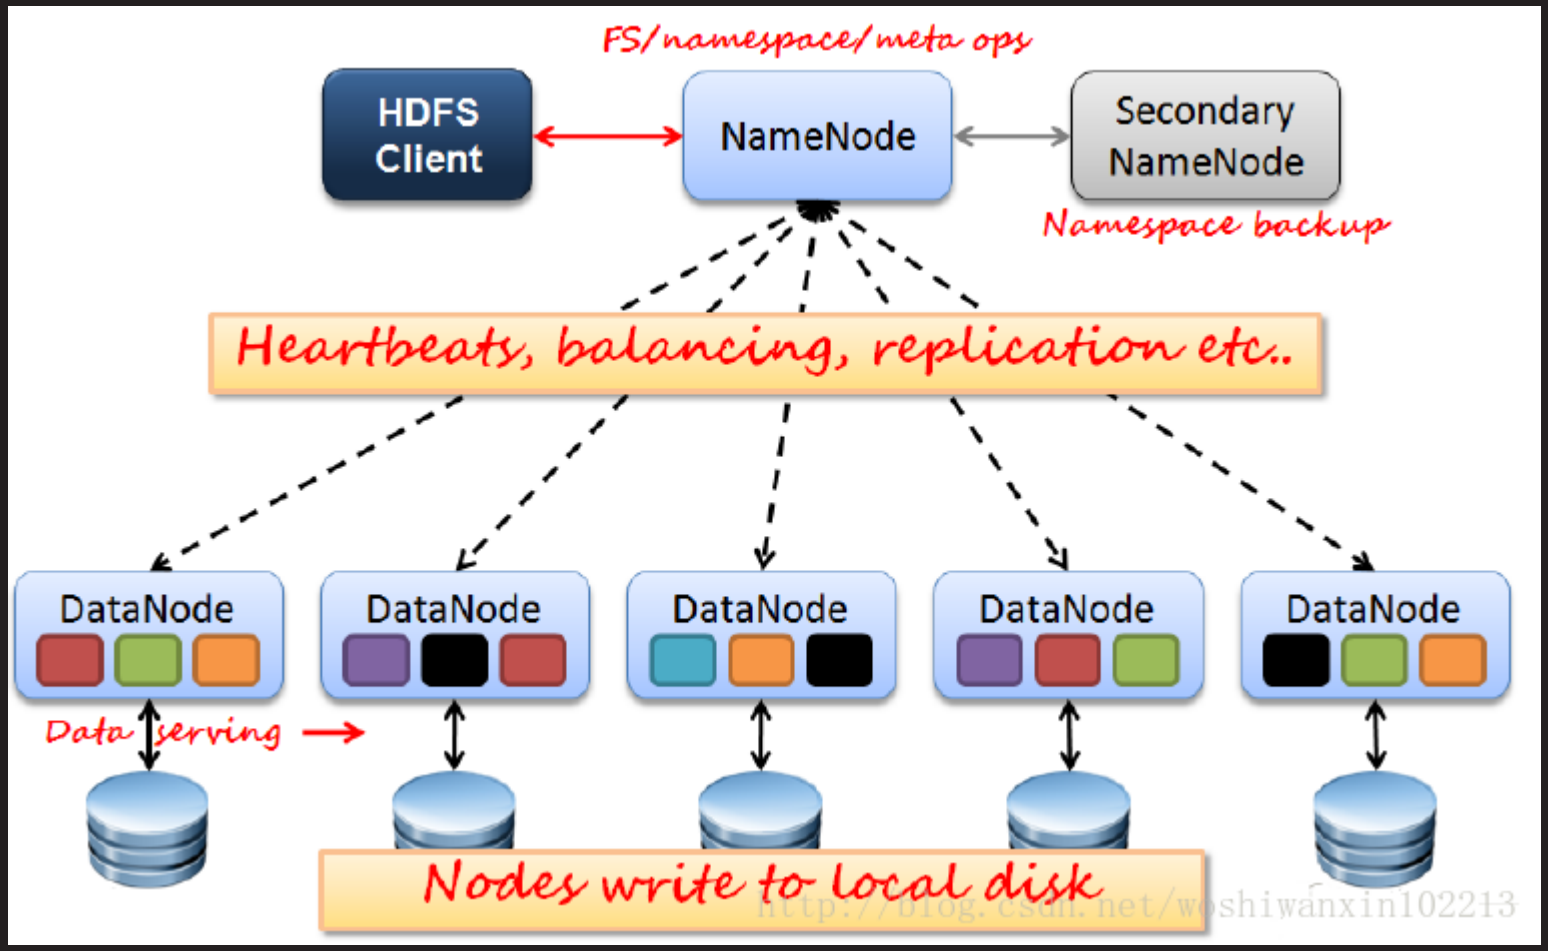

HDFS 角色及概念

- 是Hadoop体系中数据存储管理的基础。它是一个高度容错的系统，用于在低成本的通用硬件上运行。

- 角色和概念
  - Client
  - Namenode
  - Secondarynode
  - Datanode

知识讲解

HDFS 角色及概念

- NameNode
  - Master节点，管理HDFS的名称空间和数据块映射信息，配置副本策略，处理所有客户端请求。
- Secondary NameNode
  - 定期合并 fsimage 和fsedits，推送给NameNode
  - 紧急情况下，可辅助恢复NameNode，
- 但Secondary NameNode并非NameNode的热备。

知识讲解

HDFS 角色及概念

- DataNode
  - 数据存储节点，存储实际的数据
  - 汇报存储信息给NameNode。

- Client
  - 切分文件
  - 访问HDFS
  - 与NameNode交互，获取文件位置信息
  - 与DataNode交互，读取和写入数据。

知识讲解

HDFS 角色及概念

- Block
  - 每块缺省64MB大小
  - 每块可以多个副本

知识讲解

MapReduce 结构

知识讲解

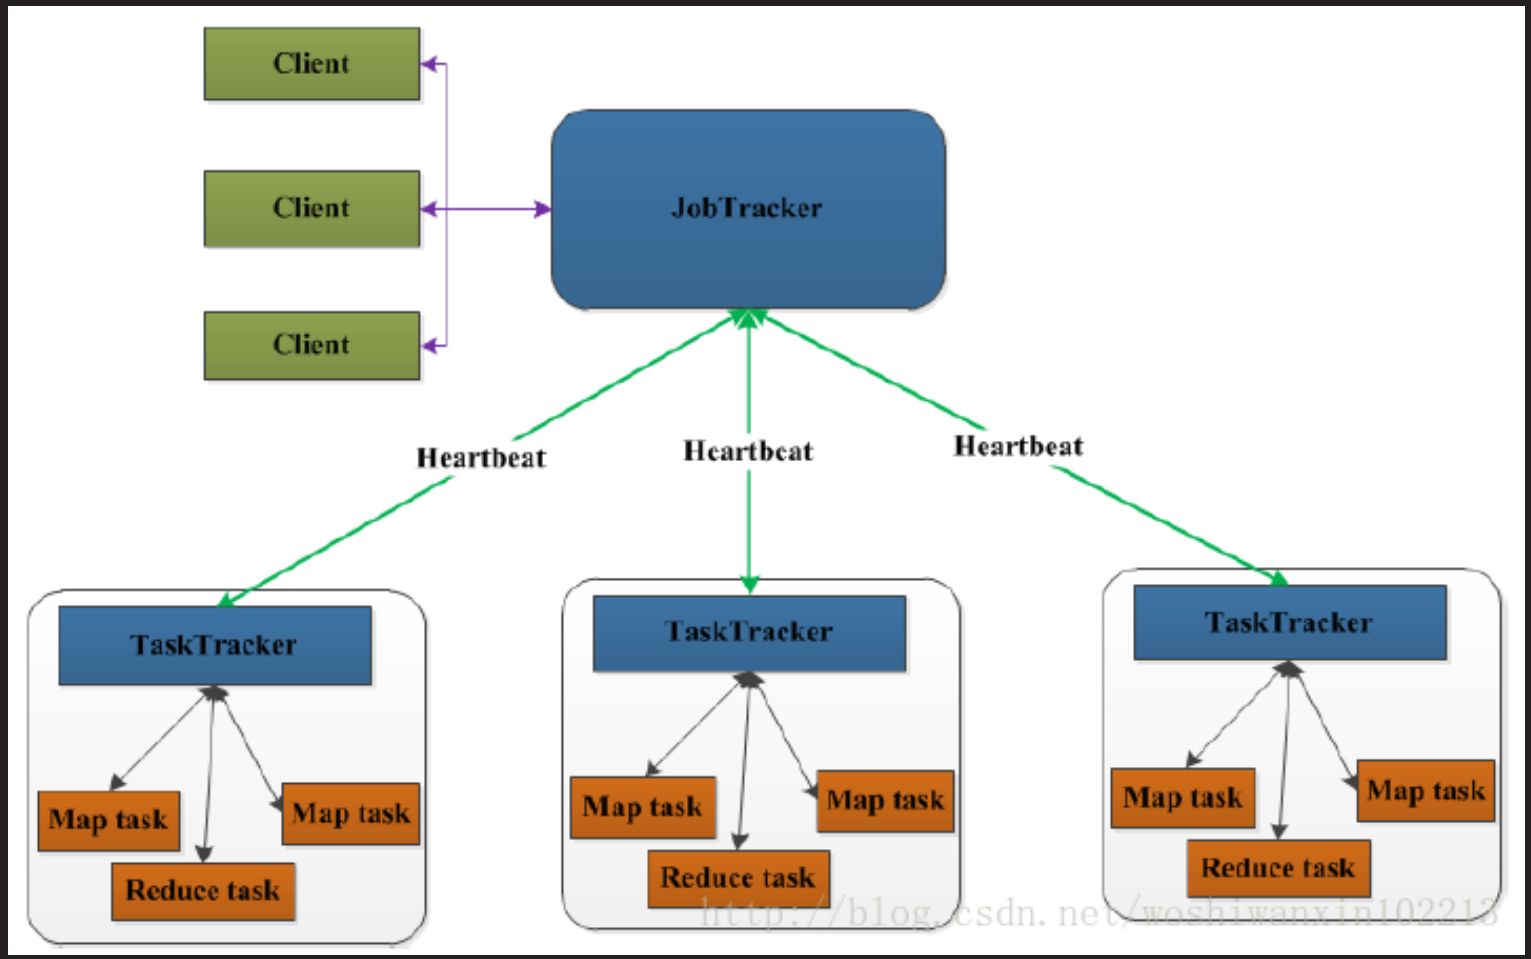

Mapreduce 角色及概念

- 源自于google的MapReduce论文，JAVA实现的分布式计算框架

- 角色和概念
  - JobTracker
  - TaskTracker
  - Map Task
  - Reduce Task

知识讲解

Mapreduce 角色及概念

- JobTracker
  - Master节点，只有一个
  - 管理所有作业
  - 作业/任务的监控、错误处理等
  - 将任务分解成一系列任务，并分派给TaskTracker。

- TaskTracker
  - Slave节点，一般是多台
  - 运行Map Task和Reduce Task
  - 并与JobTracker交互，汇报任务状态。

知识讲解

Mapreduce 角色及概念

- Map Task：解析每条数据记录，传递给用户编写的map(),并执行，将输出结果写入本地磁盘(如果为map-only作业，直接写入HDFS)。

- Reducer Task：从Map Task的执行结果中，远程读取输入数据，对数据进行排序，将数据按照分组传递给用户编写的reduce函数执行。

知识讲解

Yarn 结构

知识讲解

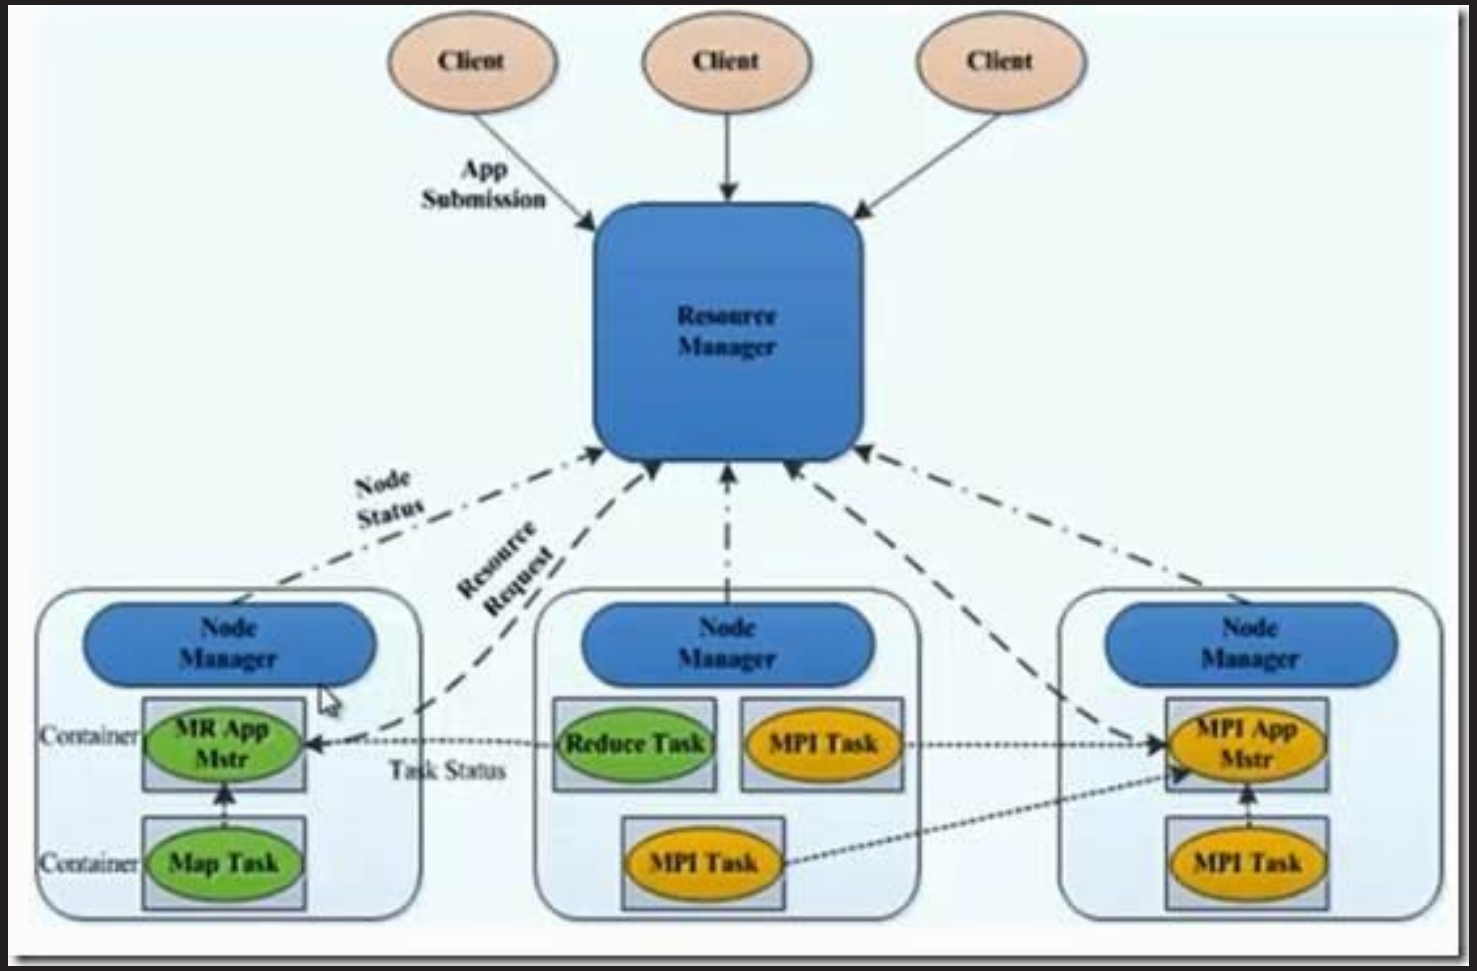

Yarn 角色及概念

- Yarn 是 Hadoop 的一个通用的资源管理系统

- Yarn 角色
  - Resourcemanager
  - Nodemanager

  - ApplicationMaster
  - Container
  - Client

知识讲解

Yarn 角色及概念

- ResourceManager
  - 处理客户端请求
  - 启动 / 监控 ApplicationMaster
  - 监控 NodeManager
  - 资源分配与调度
- NodeManager
  - 单个节点上的资源管理
  - 处理来自 ResourceManager 的命令
  - 处理来自 ApplicationMaster 的命令

知识讲解

Yarn 角色及概念

- Container
  - 对任务运行行环境的抽象，封装了 CPU 、内存等
  - 多维资源以及环境变量、启动命令等任务运行相关的信息资源分配与调度
- ApplicationMaster
  - 数据切分
  - 为应用程序申请资源，并分配给内部任务
  - 任务监控与容错

知识讲解

Yarn 角色及概念

- Client
  - 用户与 YARN 交互的客户端程序
  - 提交应用程序、监控应用程序状态，杀死应用程序等

知识讲解

Yarn 角色及概念

- YARN 的核心思想
- 将 JobTracker 和 TaskTacker 进行分离，它由下面几大构成组件：
  - ResourceManager 一个全局的资源管理器
  - NodeManager 每个节点(RM)代理
  - ApplicationMaster 表示每个应用
  - 每一个 ApplicationMaster 有多个 Container 在 NodeManager 上运行

知识讲解

Hadoop 安装配置

Hadoop 安装配置

- Hadoop 的部署模式有三种
  - 单机
  - 伪分布式
  - 完全分布式

知识讲解

Hadoop 单机模式安装配置

知识讲解

- Hadoop 的单机模式安装非常简单
  - 1、获取软件
    http://hadoop.apache.org
  - 2、安装配置 java 环境，安装 jps 工具
    安装 Openjdk 和 openjdk-devel
  - 3、设置环境变量，启动运行
  - hadoop-env.sh
    JAVA_HOME= “”

Hadoop 单机模式安装配置

- Hadoop 的单机模式安装非常简单，只需要配置好环境变量即可运行，这个模式一般用来学习和测试 hadoop 的功能
  - 测试 --- 统计词频

```
cd  /usr/local/hadoop
mkdir  input
cp *.txt input/
./bin/hadoop jar ./share/hadoop/mapreduce/hadoop-mapreduce-examples-2.7.3.jar wordcount input output
```

知识讲解

Hadoop 伪分布式

- 伪分布式
  - 伪分布式的安装和完全分布式类似，但区别是所有角色安装在一台机器上，使用本地磁盘，一般生产环境都会使用完全分布式，伪分布式一般用来学习和测试方面的功能
  - 伪分布式的配置和完全分布式配置类似

知识讲解

Hadoop 配置文件及格式

- 文件格式
  - Hadoop-env.sh

    JAVA_HOME

    HADOOP_CONF_DIR
  - Xml 文件配置格式

```
<property>
        <name>关键字</name>
        <value>变量值</value>
        <description> 描述 </description>
</property>
```

知识讲解

Tedu.cn
达内教育

HDFS 分布式文件系统

完全分布式

- 系统规划

主机	角色	软件
192.168.1.10 Nn01	NameNode SecondaryNameNode	HDFS
192.168.1.11 Node1	DataNode	HDFS
192.168.1.12 Node2	DataNode	HDFS
192.168.1.13 node3	DataNode	HDFS

知识讲解

搭建完全分布式

知识讲解

- 基础环境准备
  - 新开启3台虚拟机
  - 禁用 selinux

    SELINUX=disabled
  - 禁用 firewalld

    systemctl stop firewalld

    systemctl mask firewalld
  - 安装 java-1.8.0-openjdk-devel

    yum install -y java-1.8.0-openjdk-devel

搭建完全分布式

- 基础环境准备
  - 在3台机器上配置 /etc/hosts
  - 注： 所有主机都能 ping 同 namenode 的主机名
  - namenode 能 ping 同所有节点

  - java -version 验证 java 安装
  - jps 验证角色

知识讲解

完全分布式

- 配置 SSH 信任关系（namenode）
  - 注意：不能出现要求输入 yes 的情况，每台机器都要能登录成功，包括本机！！！
  - ssh_config

    StrictHostKeyChecking no
  - ssh-keygen -b 2048 -t rsa -N '' -f key
  - ssh-copy-id -i ./key.pub root@ip.xx.xx.xx

知识讲解

完全分布式

- HDFS 完全分布式系统配置
  - 环境配置文件 hadoop-env.sh
  - 核心配置文件 core-site.xml
  - HDFS配置文件 hdfs-site.xml
  - 节点配置文件 slaves

知识讲解

完全分布式

- 环境配置文件 hadoop-env.sh
  - openjdk 的安装目录
  - JAVA_HOME
  - hadoop 配置文件的存放目录
  - HADOOP_CONF_DIR

知识讲解

完全分布式

- 核心配置文件 core-site.xml
  - fs.defaultFS 文件系统配置参数
  - hadoop.tmp.dir 数据目录配置参数

```
<property>
    <name>fs.defaultFS</name>
    <value>hdfs://nn01:9000</value>
</property>
<property>
    <name>hadoop.tmp.dir</name>
    <value>/var/hadoop</value>
</property>
```

知识讲解

完全分布式

- HDFS 配置文件 hdfs-site.xml
  - namenode 地址声明
  - dfs.namenode.http-address
  - secondarynamenode 地址声明
  - dfs.namenode.secondary.http-address
  - 文件冗余份数
  - dfs.replication

知识讲解

完全分布式

- HDFS 配置文件 hdfs-site.xml

```
<property>
    <name>dfs.namenode.http-address</name>
    <value>nn01:50070</value>
</property>
<property>
    <name>dfs.namenode.secondary.http-
address</name>
    <value>nn01:50090</value>
</property>
<property>
    <name>dfs.replication</name>
    <value>2</value>
</property>
```

知识讲解

完全分布式

- 节点配置文件 slaves
  - 只写 datanode 节点的主机名称

    node1
    node2
    node3

  - 同步配置
  - hadoop 所有节点的配置参数完全一样，我们在一台配置好以后，要把配置文件分发到其它所有主机上去

知识讲解

完全分布式

- HDFS 完全分布式配置
  - 在所有机器上创建 /var/hadoop 文件夹

    mkdir /var/hadoop
  - 在 namenode 上执行格式化操作

    ./bin/hdfs namenode -format
  - 启动集群

    ./sbin/start-dfs.sh

知识讲解

完全分布式

- JPS验证角色：
  - namenode 验证

```
[root@nn01 hadoop]# jps
29826 SecondaryNameNode
31237 Jps
29643 NameNode
```

  - datanode 验证

```
[root@node1 ~]# jps
24472 Jps
24027 DataNode
```

知识讲解

完全分布式

- 节点验证：
  - namenode 上
  - bin/hdfs dfsadmin -report

```
[root@nn01 hadoop]# bin/hdfs dfsadmin -report
Configured Capacity: 51505004544 (47.97 GB)
DFS Used: 733184 (716 KB)
... ...
Missing blocks: 0
Missing blocks (with replication factor 1): 0
-------------------------------------------------
Live datanodes (3):
```

知识讲解

课程知识点总结

- 大数据的 5V 特性是什么？
  - (V)olume (大体量)
  - (V)ariety(多样性)
  - (V)elocity(时效性)
  - (V)eracity(准确性)
  - (V)alue(大价值)

知识讲解

课程知识点总结

知识讲解

- Hadoop 是用什么语言开发的？
  - JAVA
- Hadoop 的三大核心组件是什么？
  - Hdfs
  - Mapreduce
  - Yarn

课程知识点总结

知识讲解

- Hadoop 有几种部署模式？
  - 单机
  - 伪分布式
  - 完全分布式
- 列举 5 种 Hadoop 的常见组件？

Tedu.cn
达内教育

总结答疑